AB-тесты для разработчиков

BY САФРОНОВА НАТАЛЬЯ

ПРОДУКТОВЫЙ АНАЛИТИК СОИСКАТЕЛЬСКОГО JOBBOARD'А

Коротко о АВ-тесте

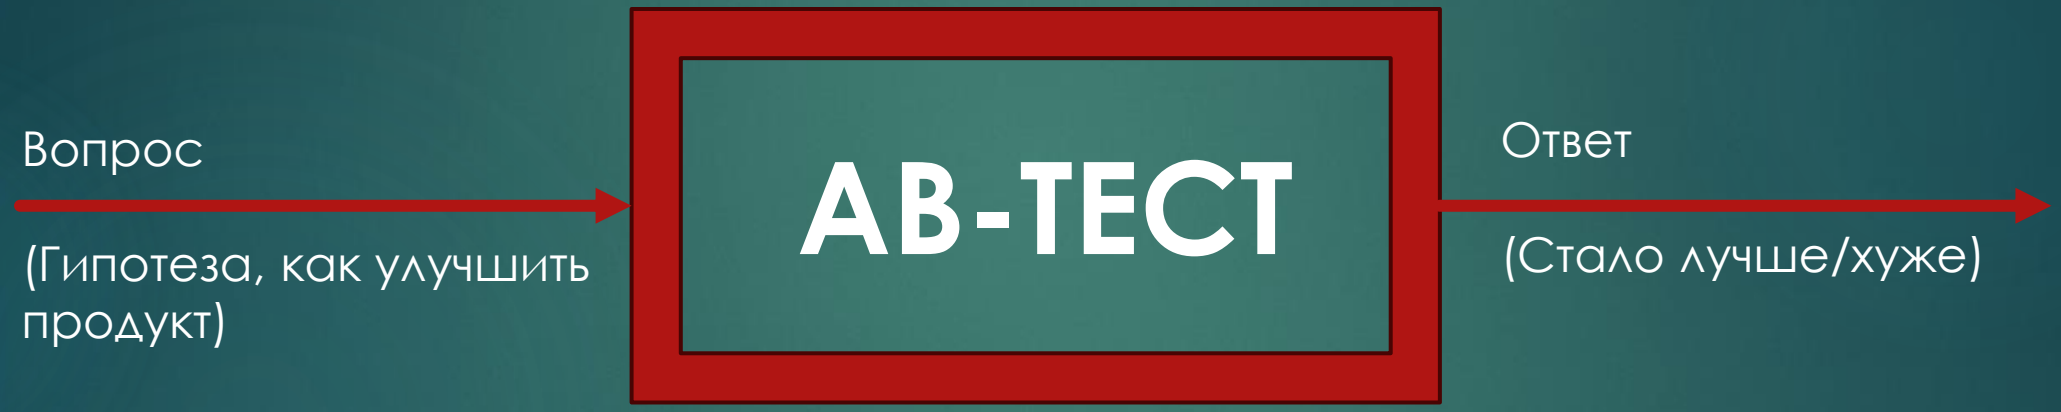

План занятия

- Зачем нужно разработчику знать про AB ?
- Что такое гипотеза и AB-тест ?
- Как проверяется гипотеза ?
- Какие виды тестов бывают ?
- Что может пойти не так ?
- Местами буду давать примеры, как устроены процессы в hh
- QA

Зачем разработчику знать, что такое АВ-тест?

Зачем разработчику знать, что такое АВ-тест?

- В продуктовой команде почти вся работа разработчика проходит через АВ-тесты
- Измеремое ценность своей работы
- Выделит на рынке или будет плюсом для повышения
- Иногда помогают найти баги
- Слаженная работа команды

Что такое гипотеза и AB-тест ?

Типичный флоу развития продукта

1. Продукт надо как-то развивать, ищем направление развития
2. Формируем гипотезу, которая приведёт нас ближе к цели
3. Дизайнеры делают макеты, разработчики переносят его в код
4. Выкатываем в прод, пользователи пользуются новой фичёй

Но как понять, сделали ли мы его лучше?

Вопрос

(Гипотеза, как улучшить продукт)

AB-ТЕСТ

Ответ

(Стало лучше/хуже)

Как сформировать гипотезу?

Добавление рейтинга на вакансию

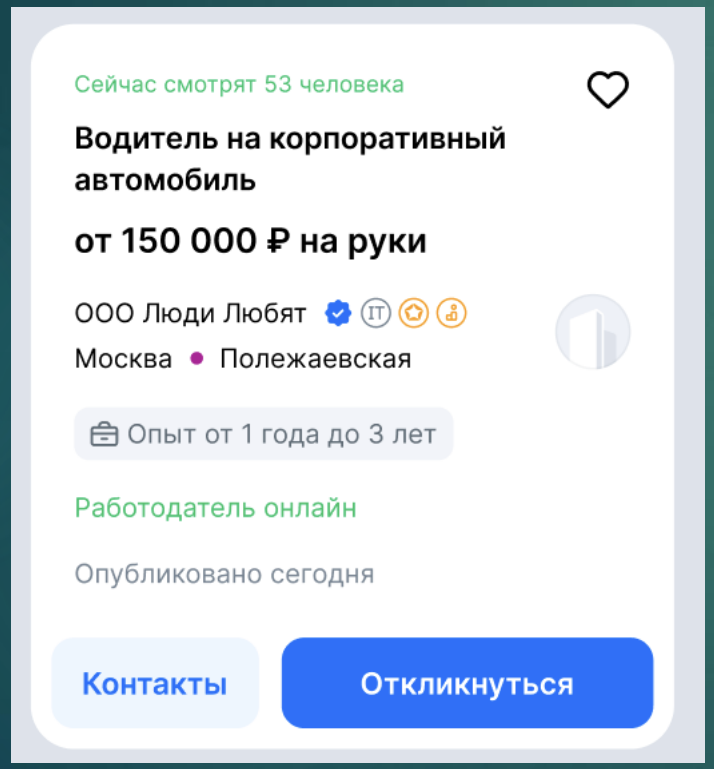

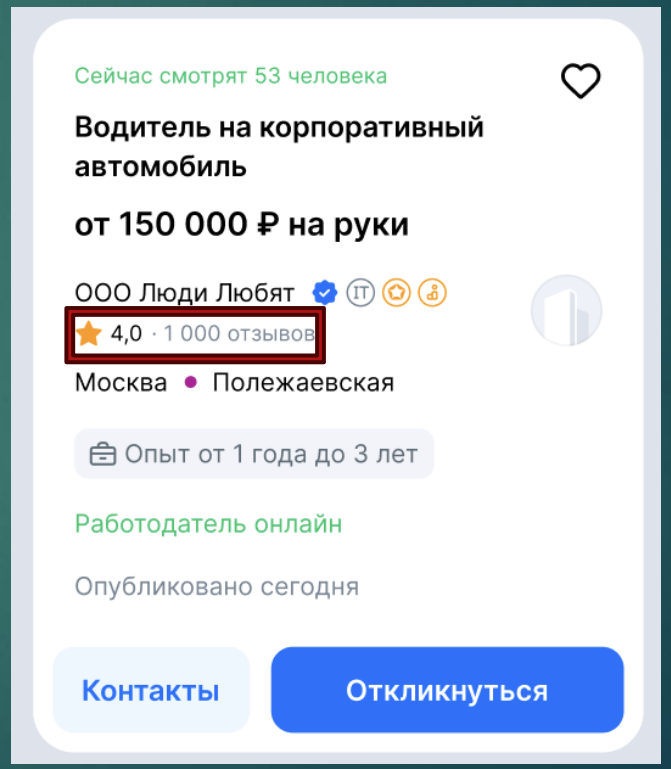

Как сформировать гипотезу?

- Гипотеза – это формализованное описание фичи и того, зачем мы её делаем

Как сформировать гипотезу?

- Гипотеза – это формализованное описание фичи и того, зачем мы её делаем

- Определиться, на кого мы хотим воздействовать
- Определиться, где хотим воздействовать

Если на сниппет вакансии добавить рейтинг, то соискатель… что-то сделает

- Необходимо определиться с целевой метрикой

Что такое метрика?

- Метрика – это численный показатель

- Доля/Конверсия

  Доля соискателей с откликом

- Среднее

  Среднее число откликов на соискателя

- Отношение

  Доля вакансий с откликом

- etc

Целевая метрика – главная метрика, на рост которой направлено изменение

Как сформировать гипотезу?

- Гипотеза – это формализованное описание фичи и того, зачем мы её делаем
- Определиться, на кого И где мы хотим воздействовать
- **Определиться с целовой метрикой**

Если на сниппете вакансии добавить рейтинг, то **доля соискателей с откликом** …

Как сформировать гипотезу?

- Гипотеза – это это формализованное описание фичи и того, зачем мы её делаем
- Определиться, на кого И где мы хотим воздействовать
- Определиться с целовой метрикой
- Зафиксировать желаемое изменение
- Дизайн фичи должен стремиться к одному [ключевому] изменению за раз

Если на сниппете вакансии добавить рейтинг, то доля соискателей с откликом вырастет [на x%].

Пример гипотезы

Если на сниппете вакансии добавить рейтинг, то доля соискателей с откликом вырастет [на x%].

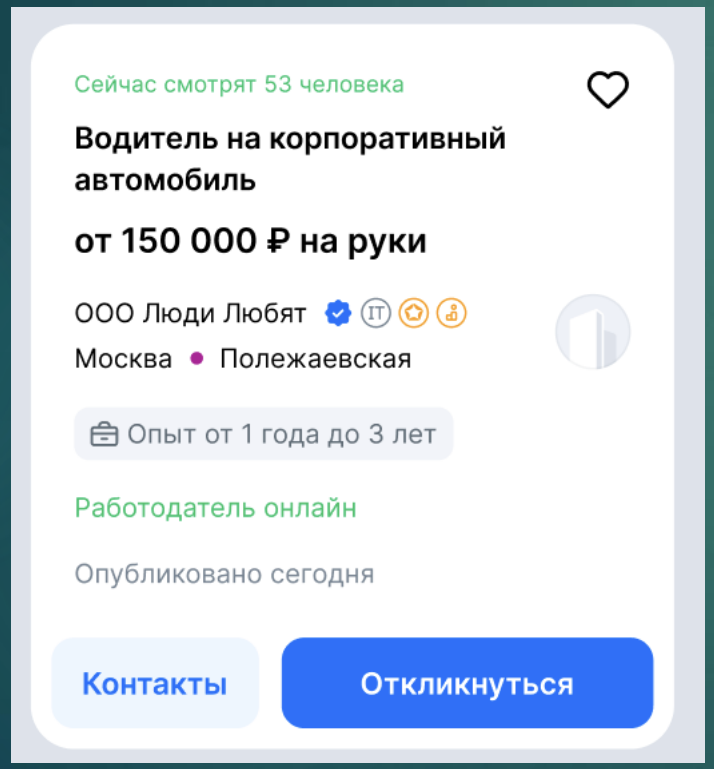

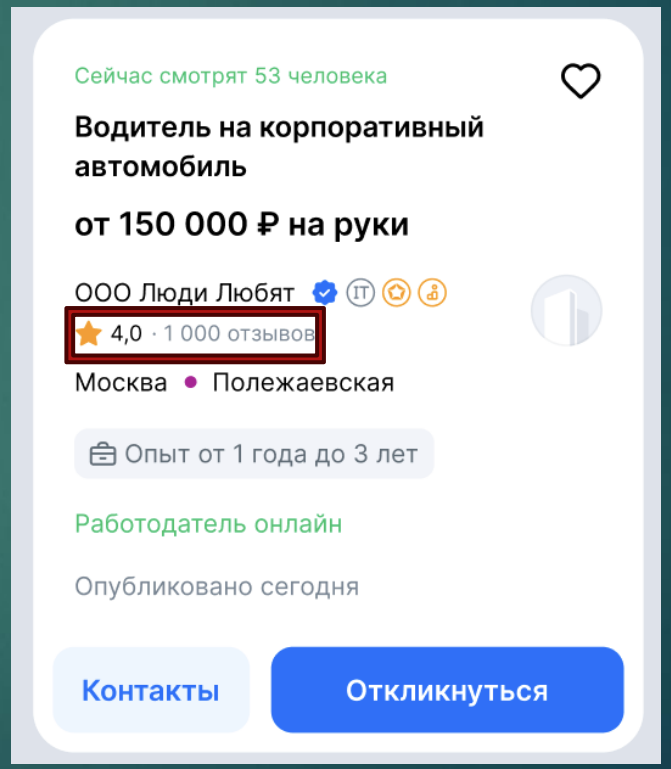

Как проверить, стало ли лучше?

Качественные исследования

- Анализ отзывов в сторе
- Глубинные интервью
- UX-тесты
- etc

Количественные исследования

- Анализ данных
- Опросы на странице
- AB-тесты
- etc

Данные после раскатки

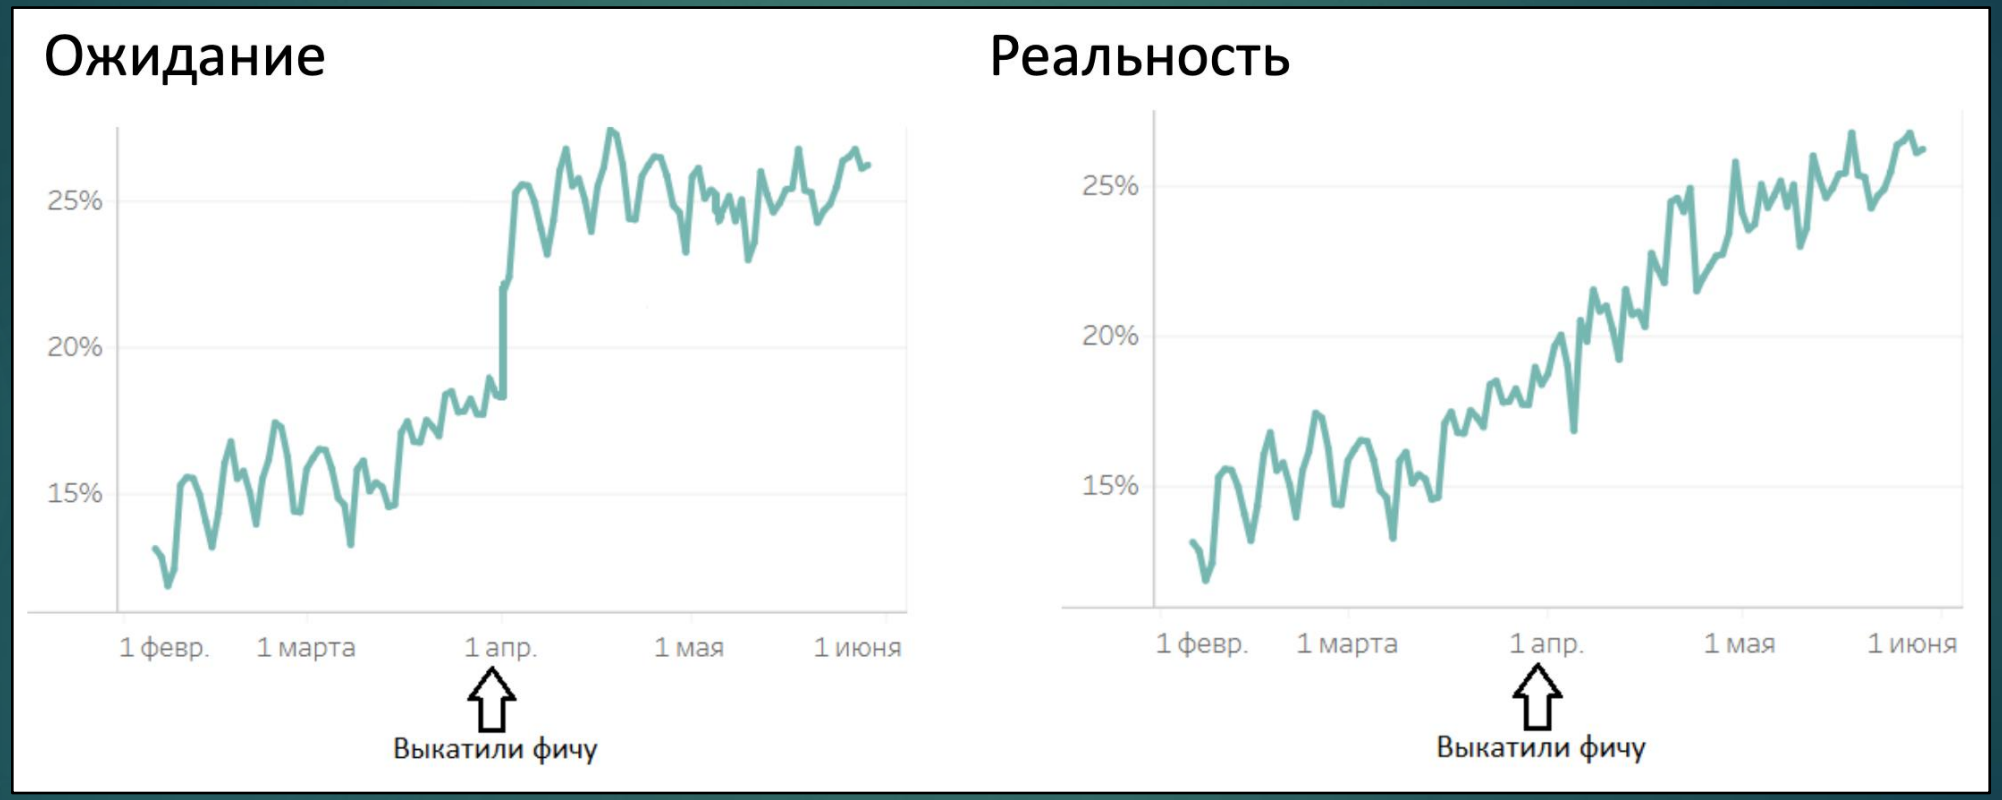

Внешние влияние, замывающее эффект от нашей фичи

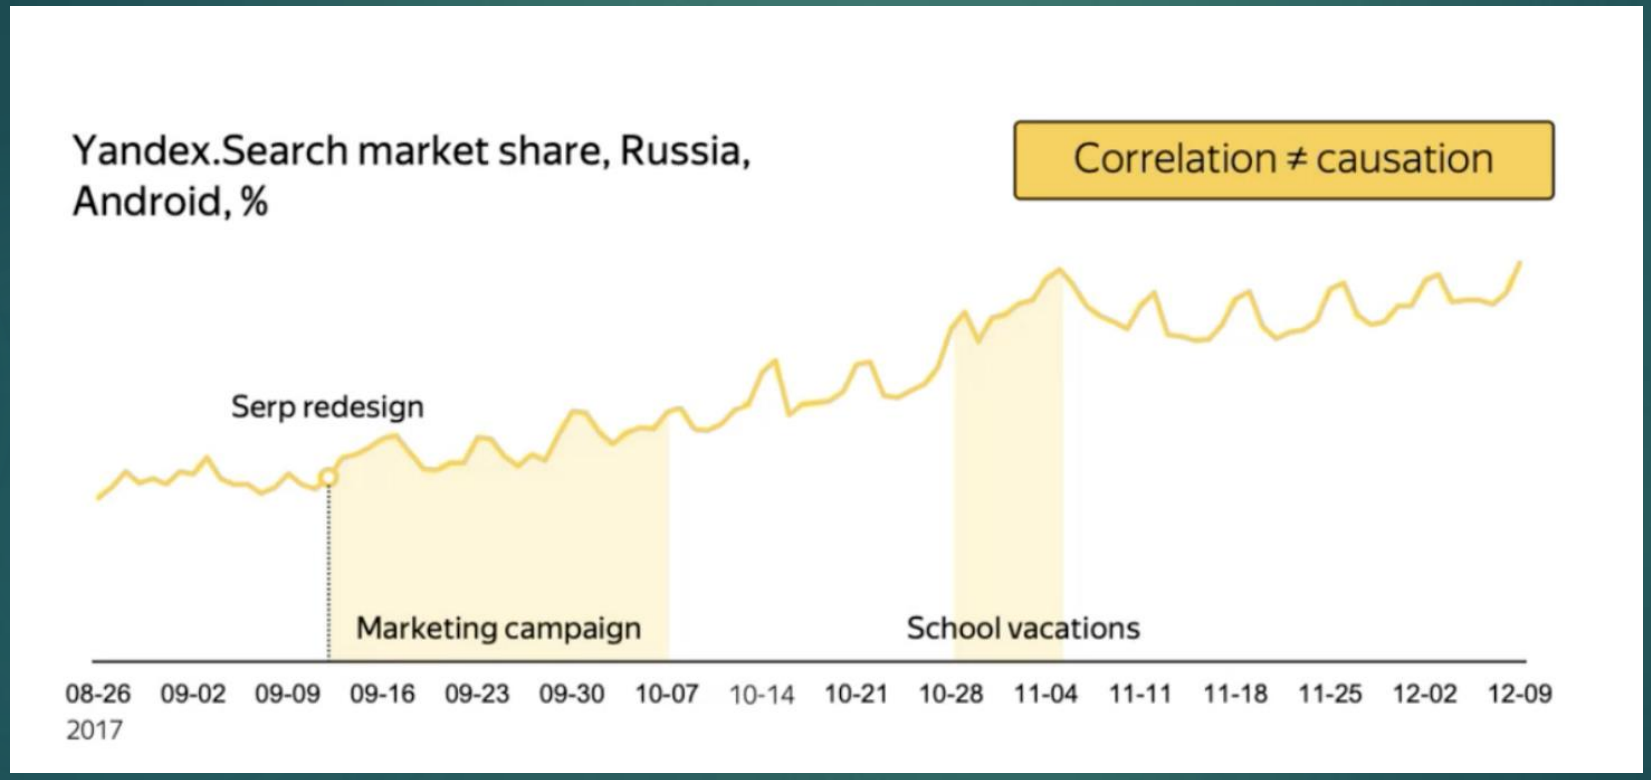

Как проверить гипотезу?

Коротко о АВ-тесте

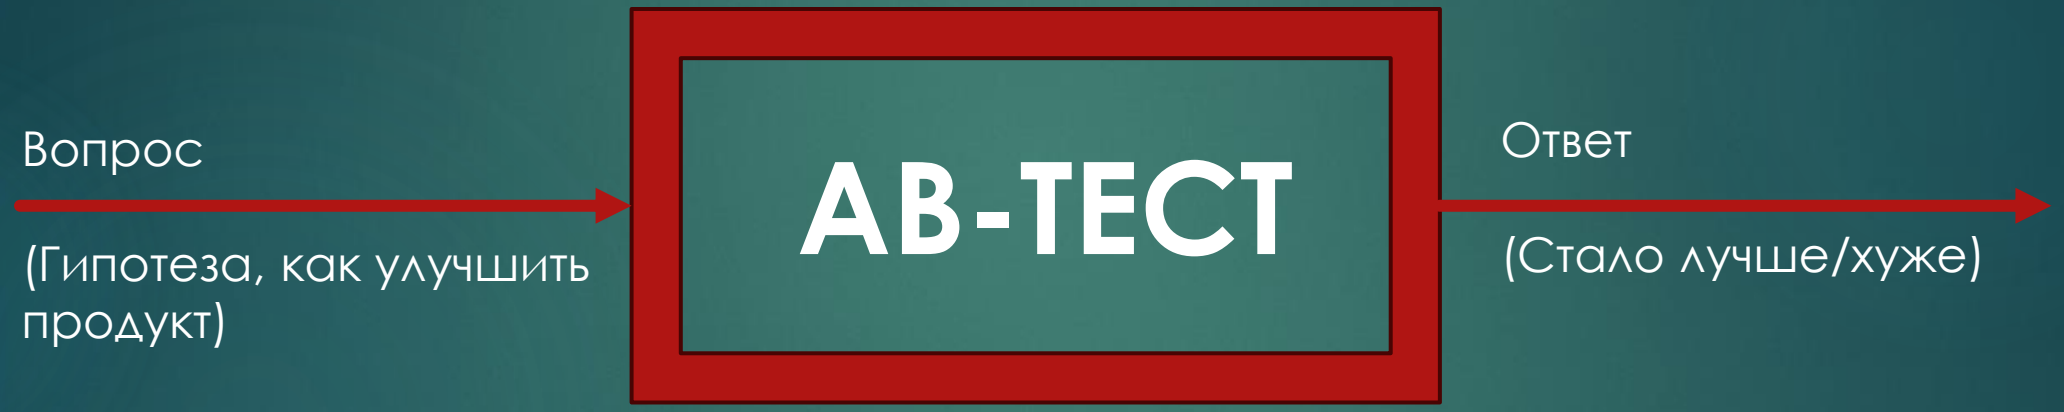

Что такое AB-тест?

- AB – случайное разбиение выборки (всей или её части) соискателей на группы (часто 2) с целью подтвердить или опровергнуть гипотезу с помощью статистических методов.

Что такое AB-тест?

ВОПРОСЫ?

Схема AB. Разбиение пользователей на группы

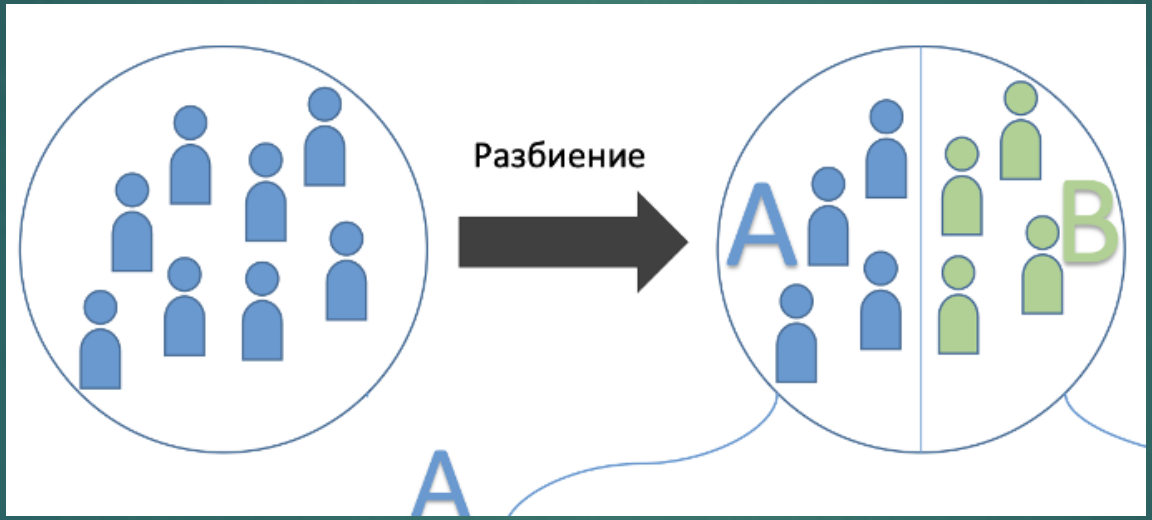

Схема AB. Разбиение пользователей на группы

- Есть пользователь Петя и у него есть уникальный идентификатор. Чтобы обеспечить случайное разбиение – берем хэш от user_id

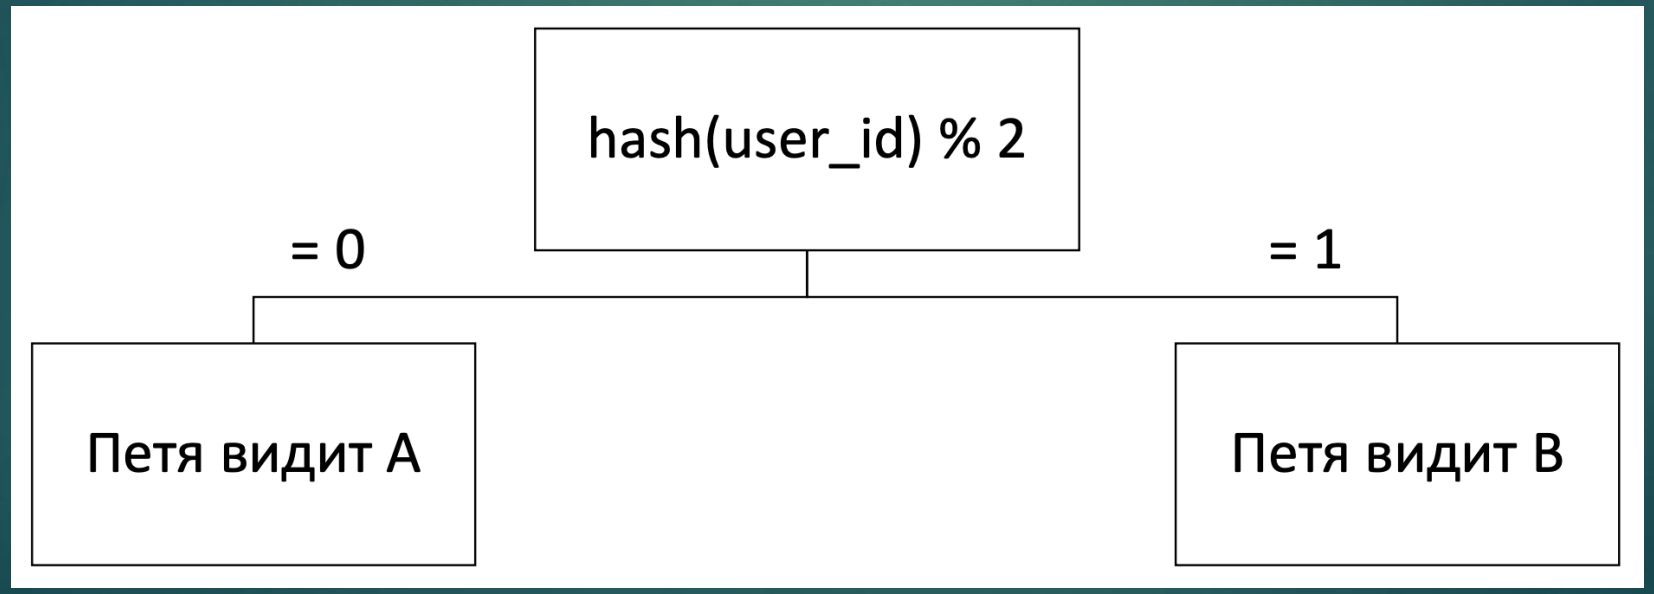

Важность случайного разбиения

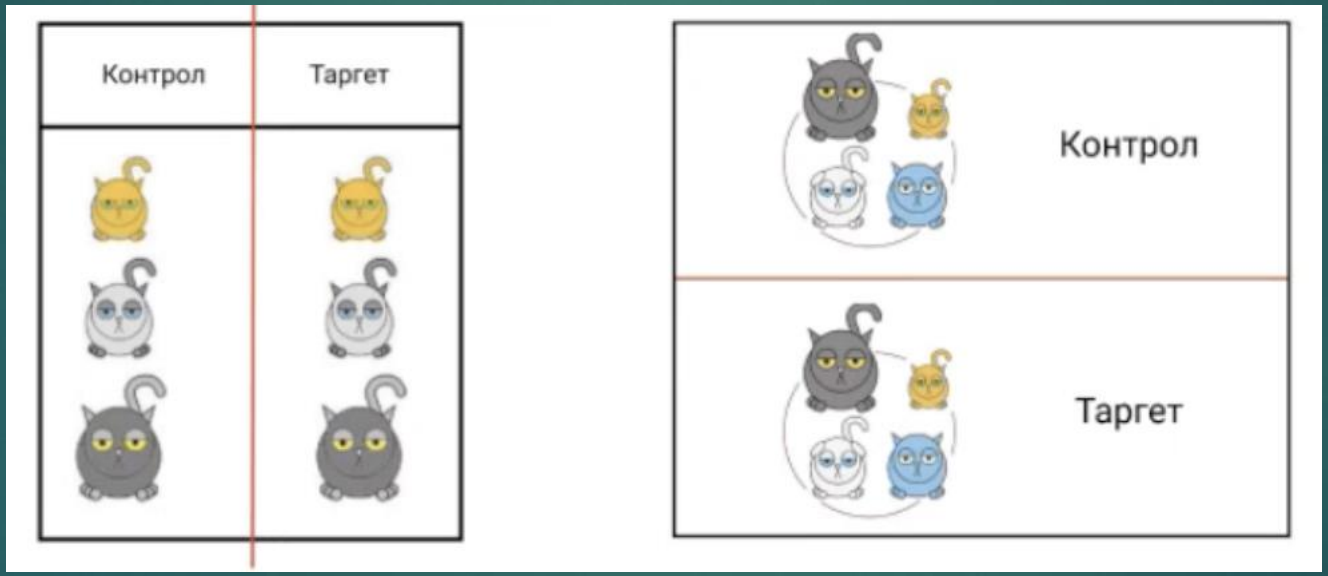

Разбиение пользователей

group_id = hash(user_id) % 2

Почему текущее решение - проблема:

- Пользователи зафиксированы в группах
- В группе накапливается эффект всех проведенных на ней экспериментов
- Статистический тест может начать ошибаться чаще

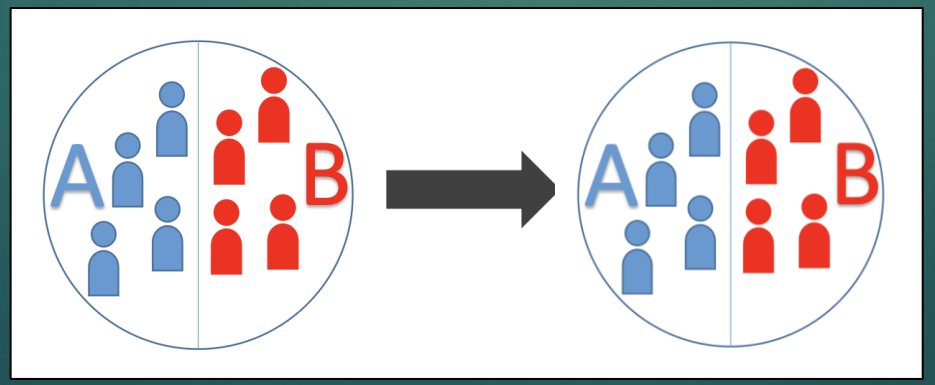

Разбиение пользователей

group_id = hash(user_id + **salt**) % 2

Решение:

- Перемешиваем пользователей в группах с помощью соли

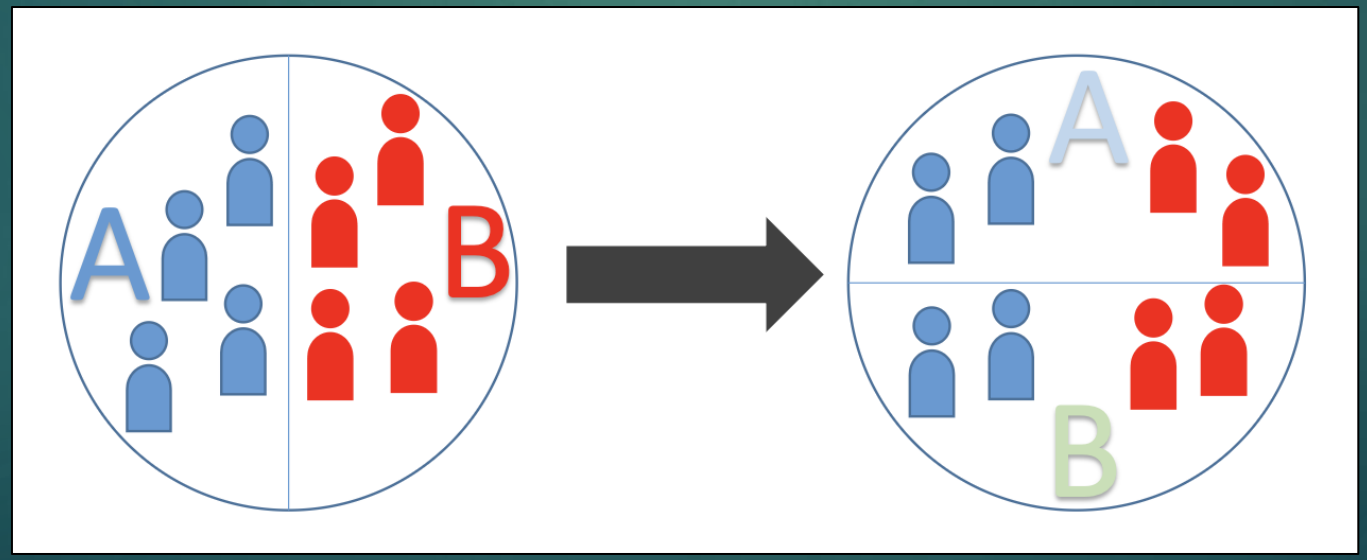

Разбиение пользователей

group_id = hash(user_id + **salt**) % 2

Решение:

- Перемешиваем пользователей в группах с помощью соли

- Соль – некая **строка**
- Меняем соль после каждого эксперимента
- Эксперименты с одинаковой **солью** считают экспериментами в одном **слое**

Разбиение пользователей

group_id = hash(user_id + salt) % 2

- Текущий вид всё ещё негибкий, т.к. спорные или дорогие в поддержке фичи хочется тестировать на части аудитории

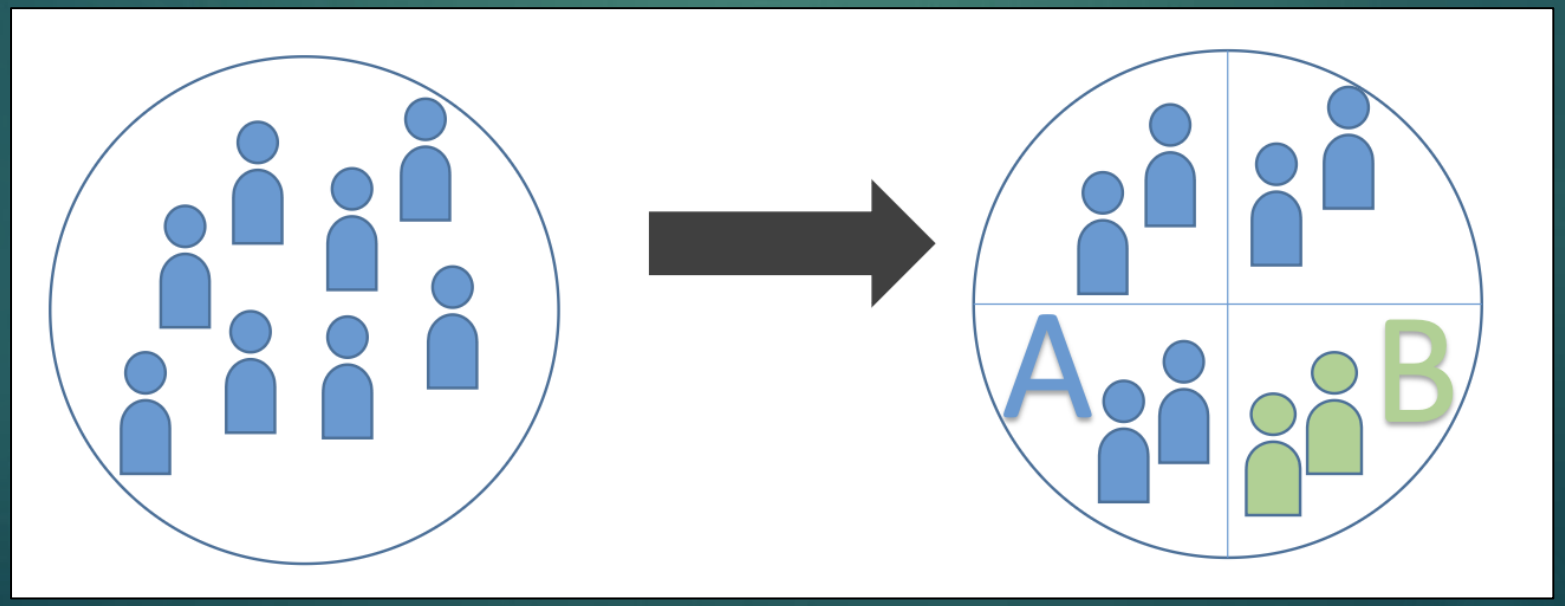

Разбиение пользователей

$$group_id = hash(user_id + salt) \% 2$$

Текущий вид всё ещё негибкий

- Спорные или дорогие в поддержке фичи хочется тестировать на части аудитории
- Часто мы хотим тестировать сразу несколько вариантов

A

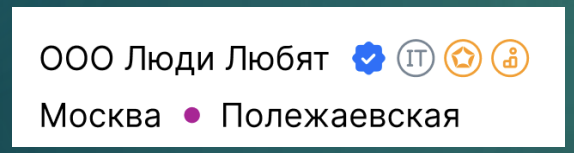

B

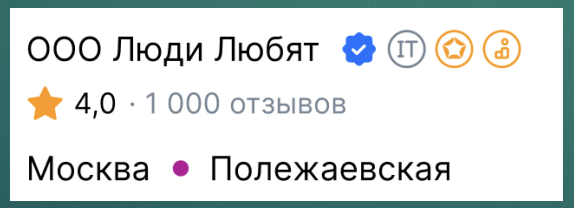

C

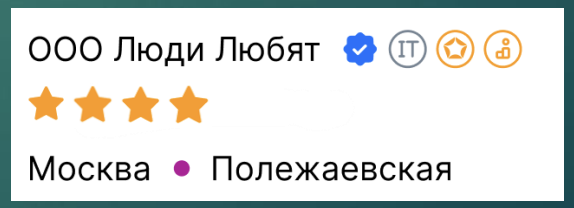

Разбиение пользователей

group_id = hash(user_id + salt) % n_**group**

Решение:

- Распределяем по остатку от деления на произвольное число групп

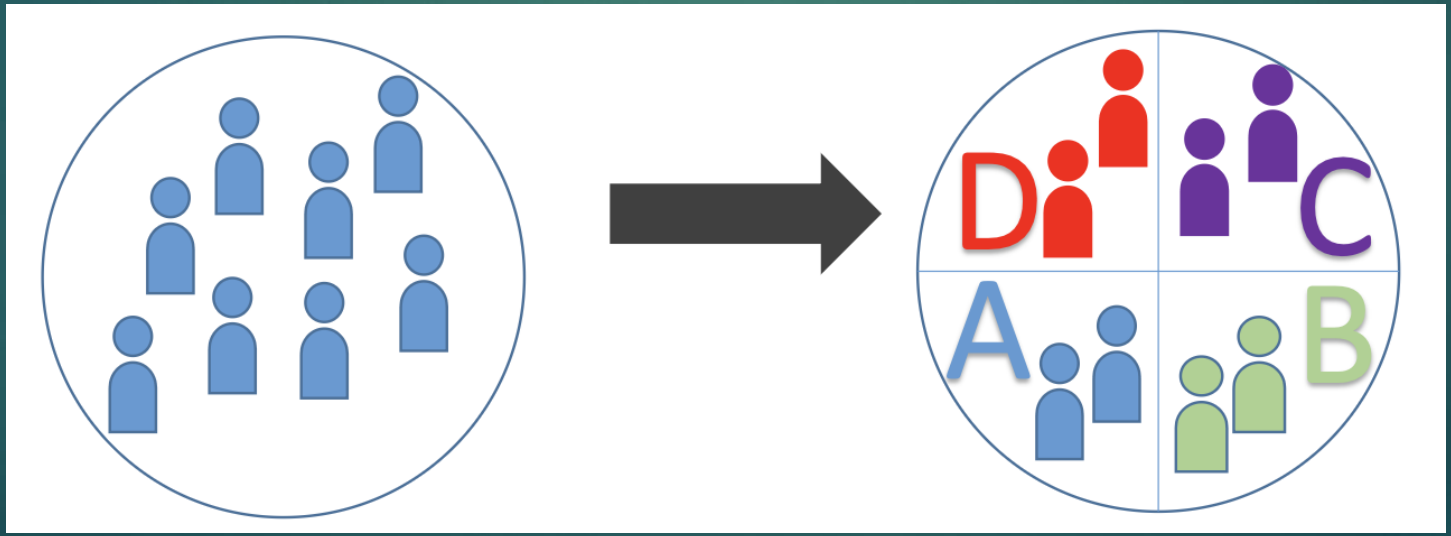

Разбиение пользователей

group_id = hash(user_id + salt) % n_**group**

Решение:

- Распределяем по остатку от деления на произвольное число групп
- Нужно знать меру по числу групп, т.к. рост числа групп вызывает
  - Растит вероятность случайного изменения
  - Увеличивает минимальный эффект, который мы можем заметить, и тест приходится проводить дольше
  - Вызывает вопросы, а точно ли гипотеза сформулировано верно

Разбиение пользователей

ВОПРОСЫ?

Порядок запуска тестов

- Параллельно с разной солью (2 независимых AB):
  - Разбиение для эксперимента B:

$group_id_B = hash(user_id + salt_B) \% n_group_B$

  - Разбиение для эксперимента C:

$group_idC = hash(user_id + salt_C) \% n_group_C$

Порядок запуска тестов

- При запуске экспериментов с разной солью получаем в итоге равновероятные все возможные комбинации

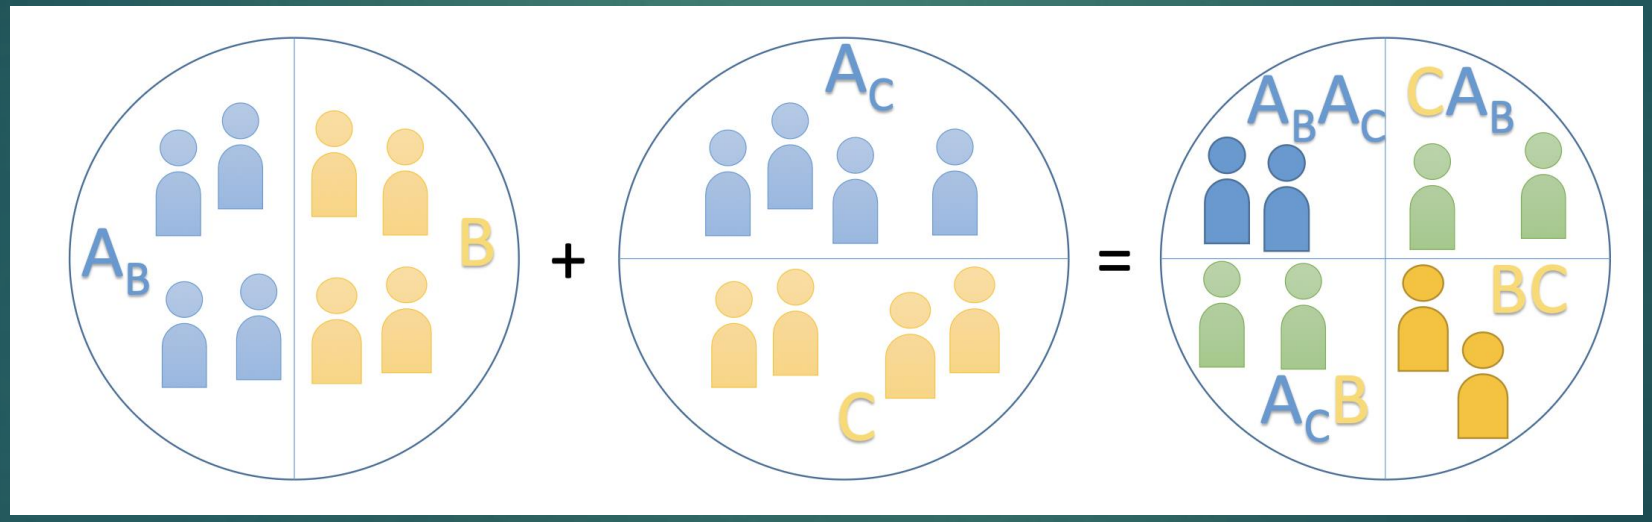

Порядок запуска тестов

- Параллельно с разной солью (2 независимых AB):
  - Плюсы: независимые эксперименты быстрее покажут результаты
  - Минусы: зависимые эксперименты (эксперименты с пересекающимися гипотезами) так запускать нельзя

	A	C
A	Регистрация бесплатно!	Регистрация бесплатно!
B	Регистрация бесплатно!	

Порядок запуска тестов

- Параллельно с разной солью (2 независимых AB)
- Параллельно с одной солью:
  - Плюсы – если изменение **альтернативное**, как с нашим рейтингом, то мы растим скорость получения результатов
  - Минусы – меньше пользователей в каждой группе – придётся дольше ждать
  - Минусы – При проверке не альтернативных экспериментов, важно учесть, не пересекаются ли их гипотезы

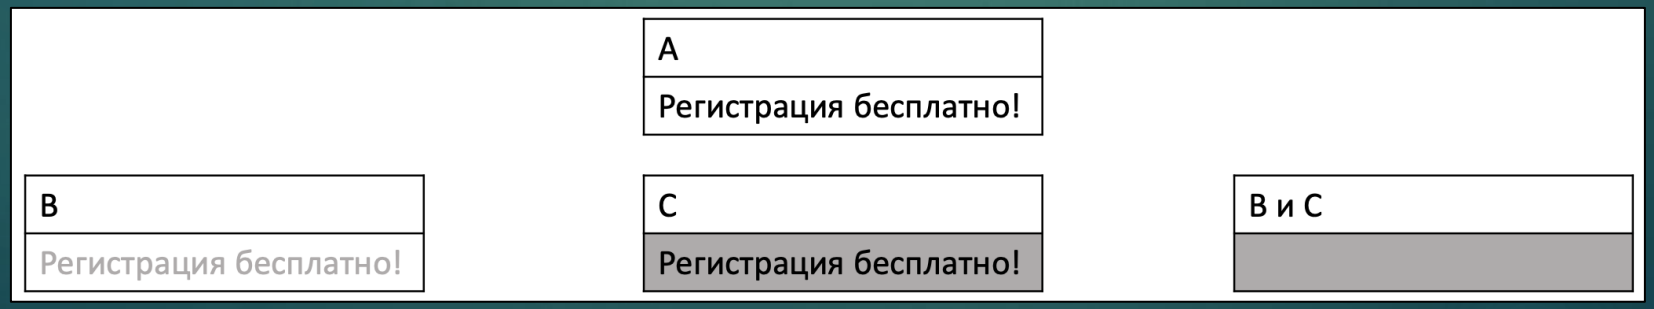

Порядок запуска тестов

- Параллельно с разной солью (2 независимых AB)
- Параллельно с одной солью
- Последовательно:
  - Плюсы – чистые результаты
  - Минусы – долго ждать

Разбиение пользователей

Главное условие проведения теста – **Число пользователей**, затронутых изменением

Если при предложенном дизайне мы получим длинные сроки проведения – 3 месяца или малое число пользователей – по 1к на группу – то стоит менять дизайн теста или запускать фичу вне эксперимента

Это экономит и время разработчика, и время аналитика

Как сделано в hh?

- Благодаря **правилу распределения** соискателей (group_id = hash(user_id + salt) % n_group) мы всегда знаем, куда попадёт соискатель, т.к. в общем случае для каждого эксперимента задаются свои n_group и salt, хэш-функция постоянная
- Дополнительно отправляется разработчиками **событие попадания в эксперимент**
- Обычно проверка происходит на фронте, но бывает в ней участвует и бек

A

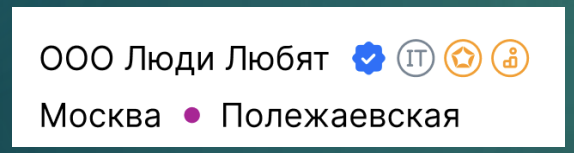

B

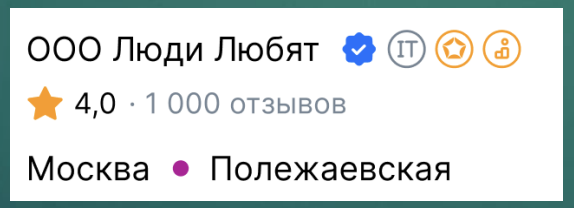

C

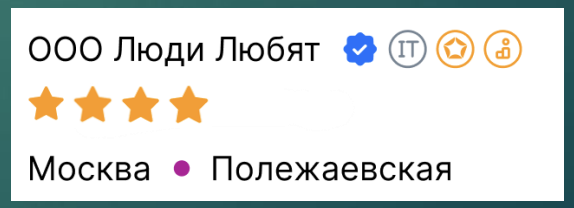

Разбиение пользователей

ВОПРОСЫ?

Проверка гипотезы

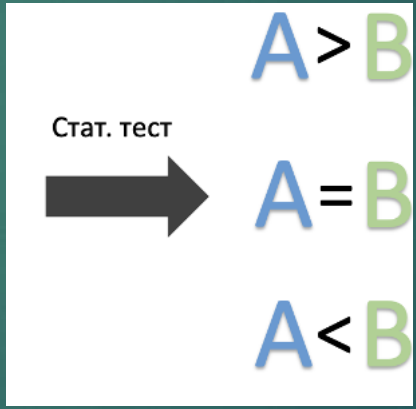

Проверка гипотезы

- Метрики в контроле A и эксперименте B чаще всего будет лежать достаточно близко, но практически никогда не будут совпадать идеально
- Какую разницу в метриках можно интерпретировать как успех?
- Какое число ошибок мы при этом допустим?

	Число пользователей	Доля зарегистировавшихся
Контрольная группа	102	82%
Экспериментальная группа	98	83%

Проверка гипотезы

- Формируем формальные гипотезы:

Нулевая гипотеза, H_0 – отсутствие различий, по умолчанию верна:

$$metrict_{reatment} = metric_{control}$$

Альтернативная гипотеза, H_1 – различия значимы, то есть то, что хотим доказать:

$$metrict_{reatment} != metric_{control}$$

H_0 – добавление рейтинга на вакансию не влияет на вероятность отклика

H_1 – добавление рейтинга на вакансию растит вероятность отклика

Проверка гипотезы

- Ошибка I рода (ложная тревога, ложноположительное срабатывание) – нашли то, чего нет

  Вероятность ошибки I рода – обозначается α, называется уровень значимости

- Ошибка II рода (пропуск события, ложноотрицательное срабатывание) – не нашли то, что есть

  Вероятность ошибки II рода – обозначается β. Отдельного названия не имеет, зато его имеет величина $1 - \beta$, которая называется **мощность или чувствительность теста**

	Разницы нет	Разница есть
Тест сказал, что разницы нет	Верно	Ошибка II рода
Тест сказал, что разница есть	Ошибка I рода	Верно

Проверка гипотезы

Проверка гипотезы

- Уровень значимости (α) – вероятность заметить изменение при условии, что его нет
- Мощность, чувствительность ($1 - \beta$) – вероятность заметить изменение при условии, что оно есть

Фиксируются заранее, как правило: **$\alpha = 5\% \Rightarrow 1 - \beta = 80\%$**

- При уменьшении уровня значимости при прочих равных растёт ошибка второго рода (уменьшается чувствительность)

$\alpha = 1\% \Rightarrow 1 - \beta = 56.36\%$

Статистический тест

- Определяет, какую функцию мы будем применять к имеющимся данным, чтобы сделать вывод о результатах. Эта функция называется тестовая статистика
- Тестовая статистика – функция от среднего/дисперсии/числа наблюдений/… посчитанным по выборке

Z-тест

$$\frac{mean_{treatment} - mean_{control}}{\sqrt{\frac{variance_{treatment}}{n_{treatment}} + \frac{variance_{control}}{n_{control}}}}$$

Требования:

- Наблюдения в выборке должны быть независимы друг от друга ?
- Нормальность распределения средних (не самих данных!) в контрольной и экспериментальной группе

- statsmodels.stats.proportions_ztest
- statsmodels.stats.weightstats.ztest
- На практике часто используют t-тест (тест Стьюдента)

Центральная предельная теорема

- Сумма достаточно большого количества слабо зависимых случайных величин, имеющих примерно одинаковые масштабы (ни одно из слагаемых не доминирует, не вносит в сумму определяющего вклада), имеет распределение, близкое к нормальному
- Если у нас достаточно много данных в выборке, исходя из ЦПТ средние будут распределены нормально
- Например, рост женщин в России; доля соискателей с откликом

Важность случайного разбиения

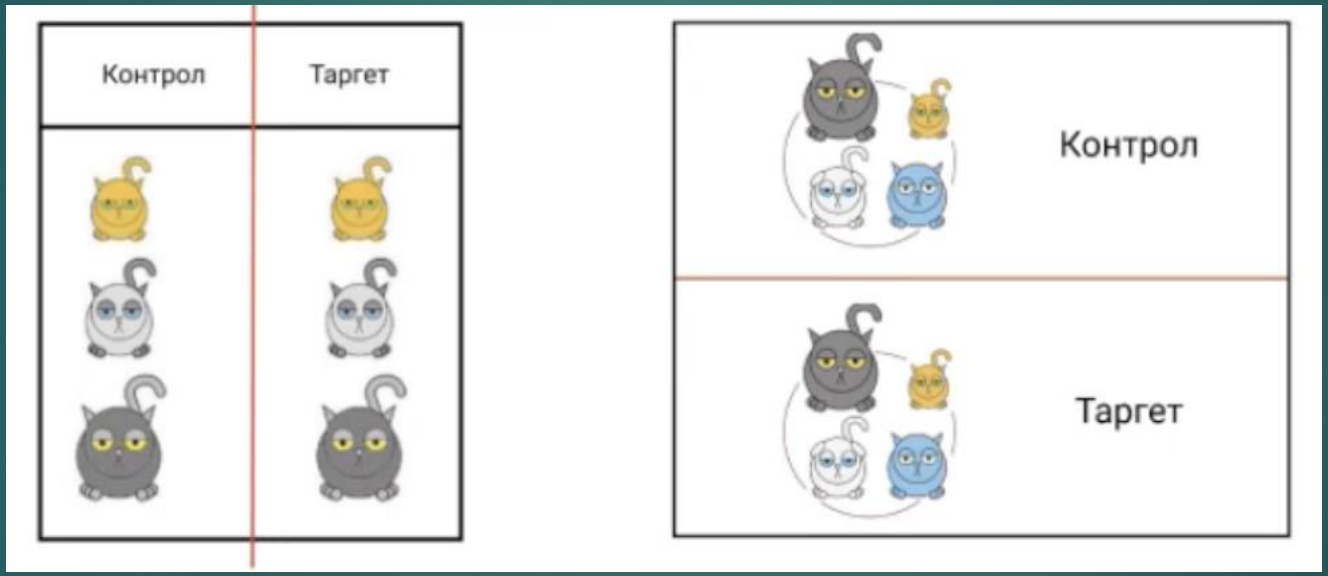

Коротко о AB-тесте

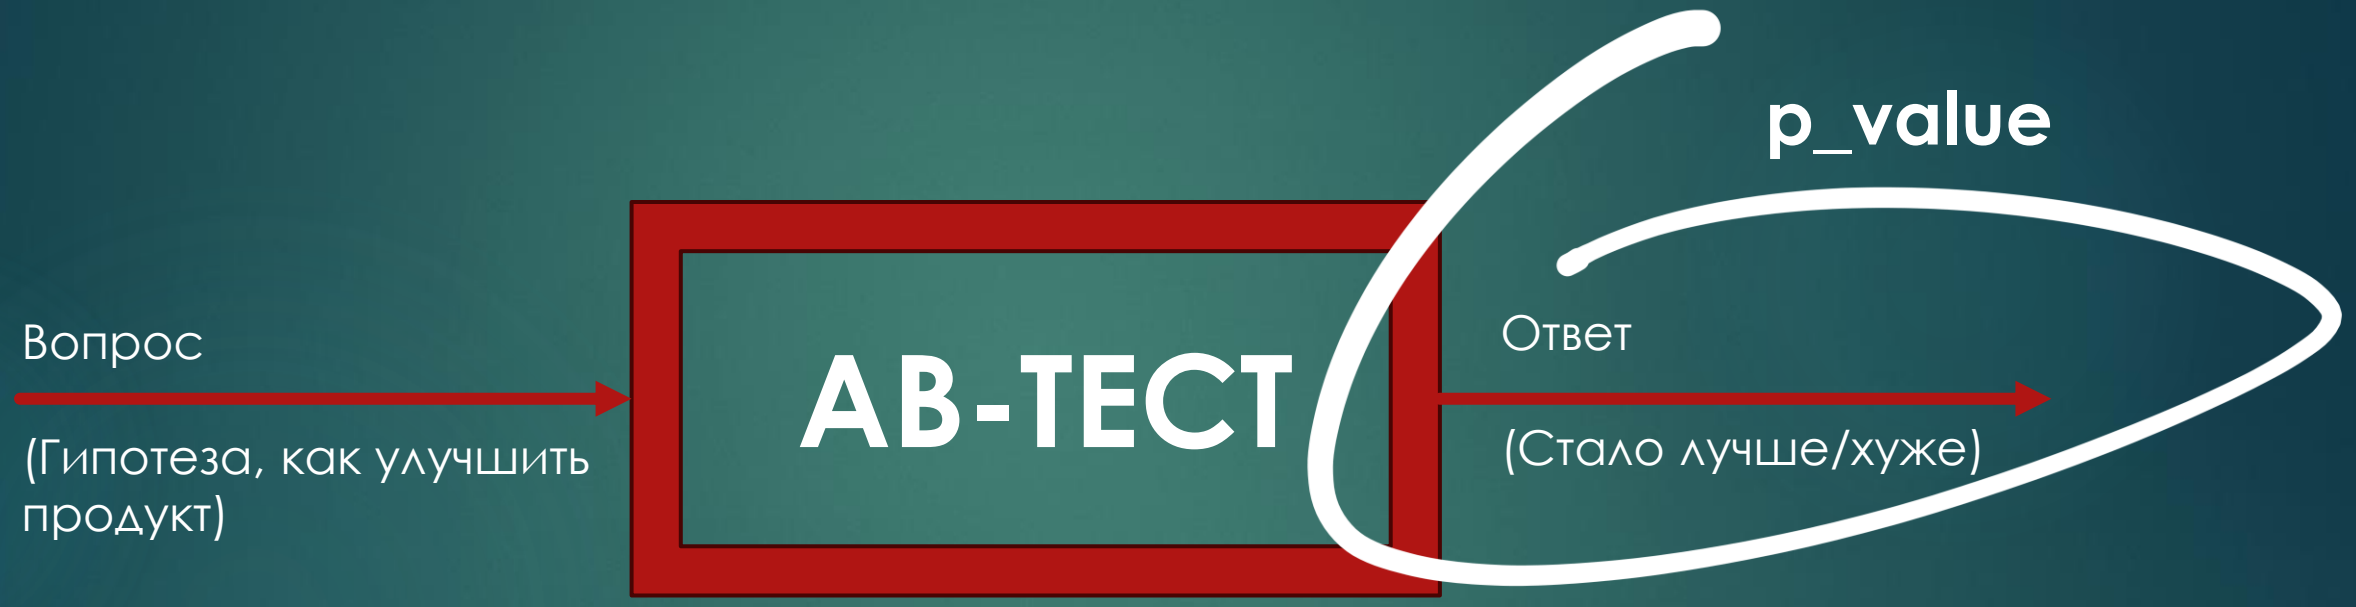

p-value – отвечает сделали ли мы лучше

- p-value - Вероятность получить такой же или более экстремальный эффект на обозреваемых данных при условии верности H_0 (эффекта нет)
- H_0 – добавление рейтинга на вакансию не влияет на вероятность отклика
- Если p-value < α – отвергаем H_0, иначе остаёмся с утверждением о верности H_0

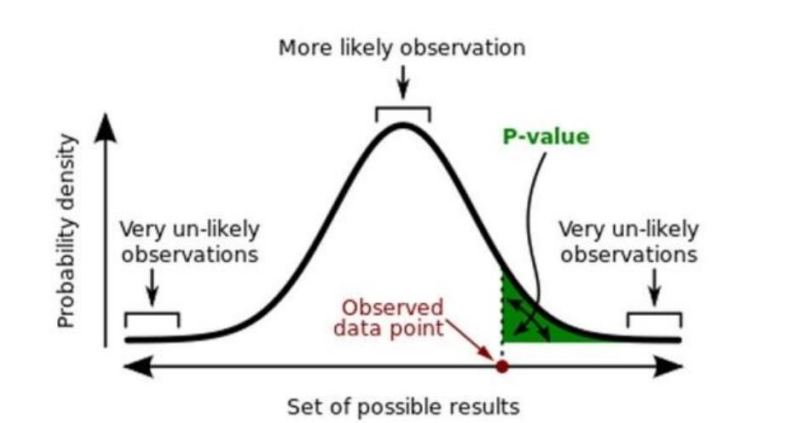

A **p-value** (shaded green area) is the probability of an observed (or more extreme) result assuming that the null hypothesis is true.

p-value – отвечает сделали ли мы лучше

Традиционная интерпретация уровней значимости при α = 0,05

Уровень значимости	Решение	Возможный статистический вывод
$p > 0,1$	Принимается H_0	«Статистически достоверные различия не обнаружены»
$p \leqslant 0,1$	сомнения в истинности H_0, неопределенность	«Различия обнаружены на уровне статистической тенденции»
$p \leqslant 0,05$	значимость, отклонение H_0	«Обнаружены статистически достоверные (значимые) различия»
$p \leqslant 0,01$	высокая значимость, отклонение H_0	«Различия обнаружены на высоком уровне статистической значимости»

$p > 0,1$ $p \leqslant 0,1$ $p \leqslant 0,05$ $p \leqslant 0,01$ $p \leqslant 0,001$

Где ещё применяются AB-тесты?

Этапы проверки статистических гипотез

Дано: $X_{treatment}$, $X_{control}$– два массива с метриками для пользователя (примерно одинаковой, но не обязательно равной длины)

- 1. Вычислить значение тестовой статистики на основе имеющихся данных (наблюдаемое значение)
- 2. Вычислить p-value– вероятность пронаблюдать такое или ещё более экстремальное значение тестовой статистики при условии, что верна H0
- 3. Если p-value < α – отвергаем H_0, иначе остаёмся с утверждением о верности H_0

Этапы проверки статистических гипотез

- p-value ≤ α и эффект положительный – зеленый прокрас/зеленый эксп/положительная статистически значимая разница
- p-value ≤ α и эффект отрицательный – красный прокрас / красный эксп/отрицательная статистически значимая разница
- p-value > α - прокарса нет/серый эксп/нет статистически значимой разницы

Коротко о AB-тесте

Вопрос

(Гипотеза, как улучшить продукт)

AB-ТЕСТ

Ответ

(Стало лучше/хуже)

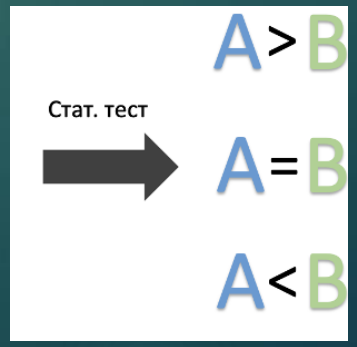

Да, стало лучше

Если на сниппете вакансии добавить рейтинг, то доля соискателей с откликом вырастет [на x%].

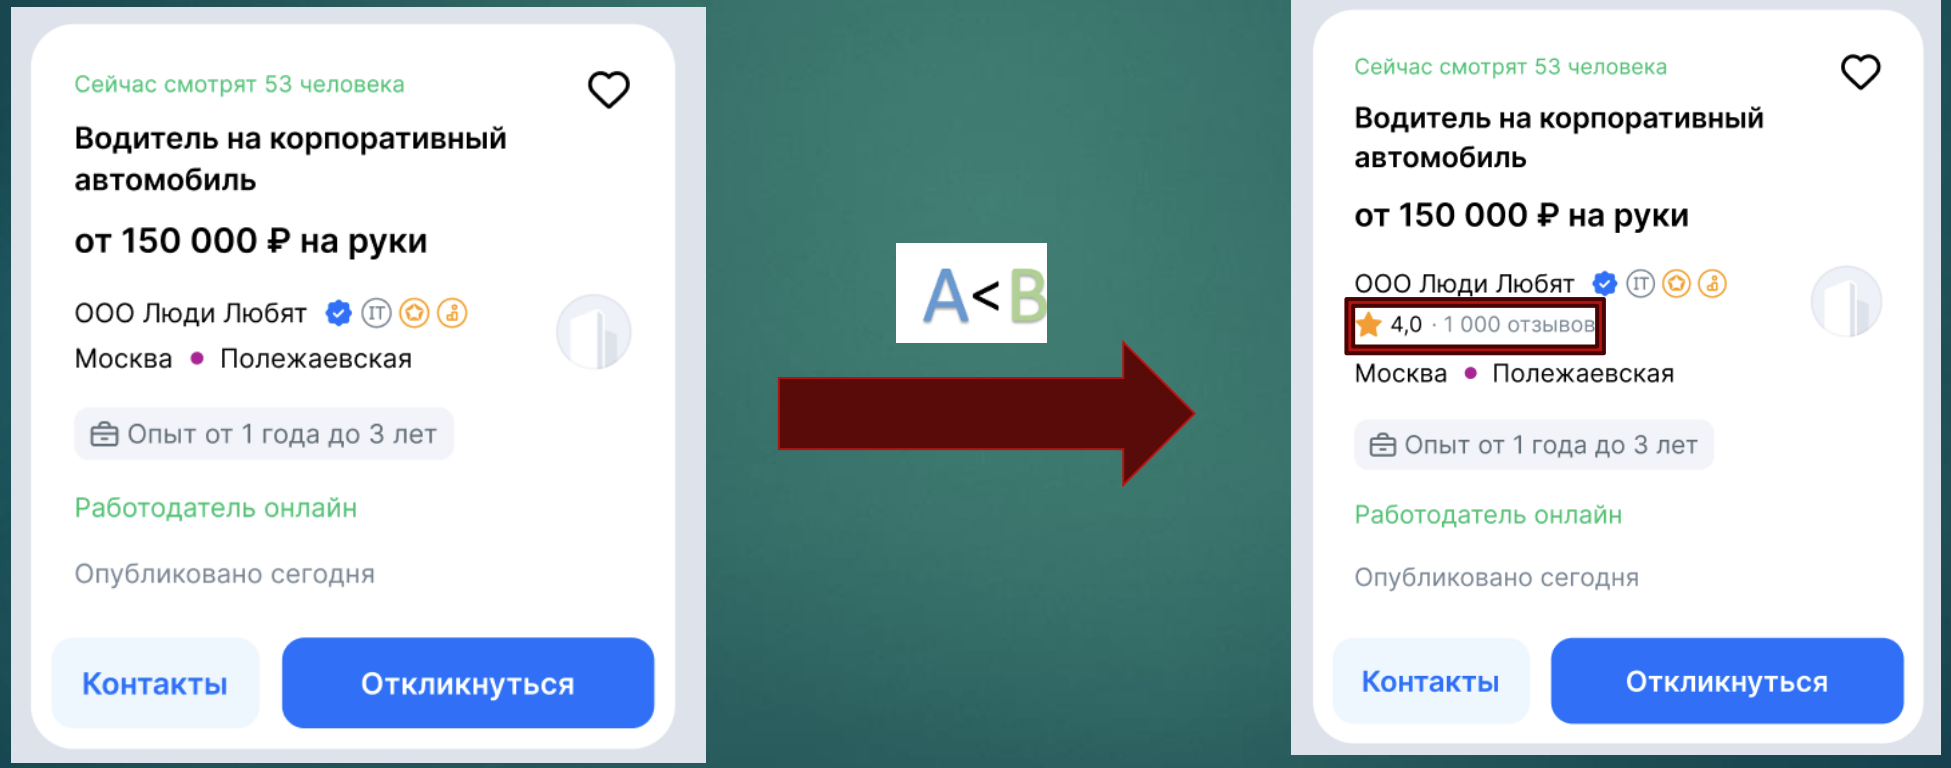

Статистический тест

ВОПРОСЫ?

Виды АВ-экспериментов

AA-эксперименты

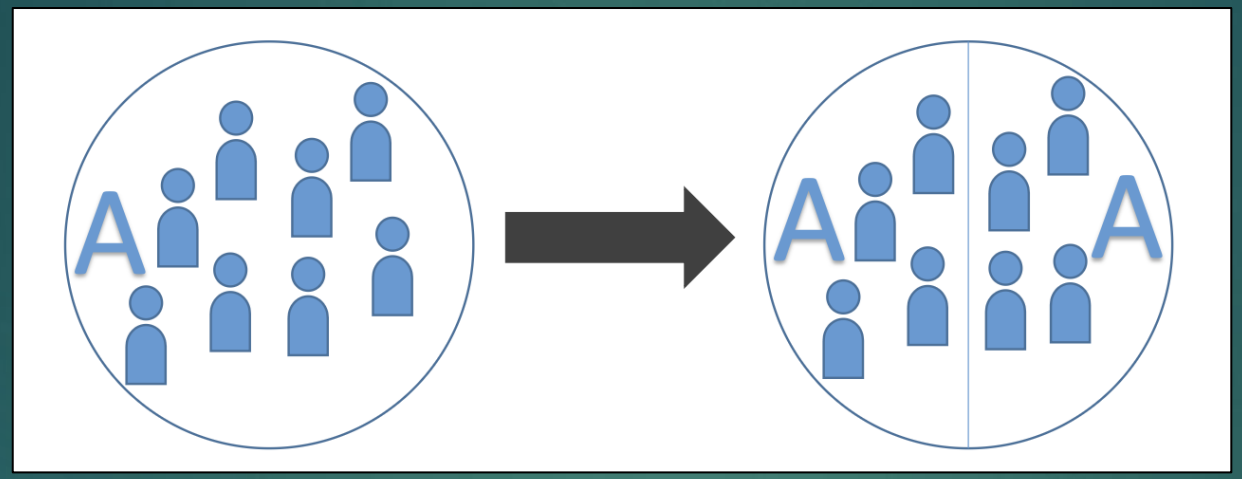

- Проводим AB-тест как обычно за одним исключением – в обеих группах показываем вариант A
- Процент экспериментов со стат значимым эффектом ~ alpha
- Часто используется для проверки системы разбиения соискателей
- Синтетический AA тест (без реального разбиения) используется для проверки метрик
- Проверка на предэкспериментальном периоде

Обратный эксперимент

- После выкатки экспериментального варианта ещё раз через какое-то время сравниваем его с контрольным
- Для некоторых экспериментов результат может проявляться только за счет эффекта новизны
- Сервис меняется – какие-то фичи могут перестать быть актуальными
- Не делаем для каждой фичи - дорого

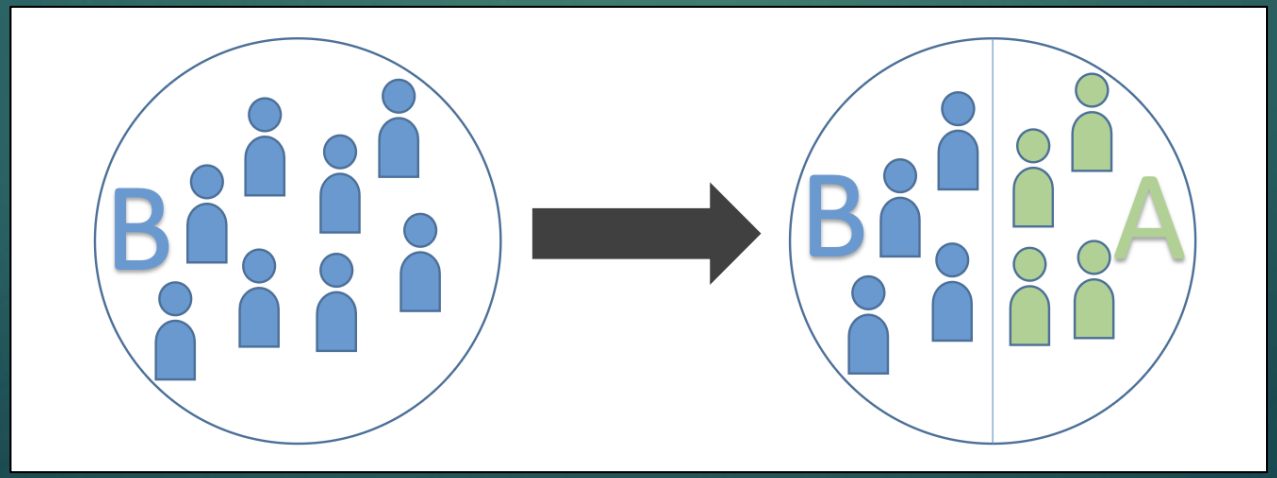

Ухудшающий эксперимент

- Уронить метрику проще, чем вырастить
- Можно получить знания, стоит ли делать фичу
  - Пример: если замедление сайта на 50 мс никак не влияет на метрики, то ускорять скорее всего смысла нет

ГроусХак или fakeDoor

- AB-тест, который мы точно не будем катить
- Делается, чтобы проверить заинтересованность пользователей до того, как начать тратить время на разработку большой фичи
- Выглядит на первый взгляд как обычная фича, но при попытке повзаимодействовать с ней пользователь получает уведомление о том, что сервис в разработке

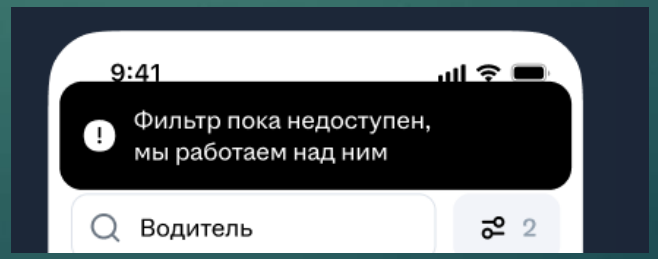

Виды АВ-экспериментов

ВОПРОСЫ?

Что может пойти не так?

Перезапуск

Перезапуск – это запуск AB-теста с нулевыми или минорными изменениями

- Хотим проверить результаты старого эксперимента, который не катили, но есть подозрения, что он уже актуальный
- Хотим проверить непонятный прокрас
- Выпустили фикс

Перекос групп

- Если разбиение пользователей завязано на работу разработчика, то очень важно, чтобы и в A, и в B были одинаковые условия попадания в эксперимент
- Если группы будут не пропорциональны (можно проеврить через scipy.stats.chisquare), то тест также сломается и его результаты будут не валидны
- Обычно можно посчитать через синтетическое разбиение пользователей по группам, но это +время подсчёта результатов и не всегда есть события, к которым можно точно привязаться для того, чтобы не брать лишних пользователей

Добавили события только в группу B

- Бывает, что для оценки пользования новой фичей могут покрываться событиями уже существующие в A элементы, которые перенесутся и в вариант B
- Если вам принесли такое событие, то лучше спросить прямо – нужно ли его добавлять и в контроль

Мискоммуникация

- Разработчик связующее звено между продуктовой идеей и продакшеном, поэтому очень важны коммуникации – с продкатом (заказчик), дизайнором, аналитиком и другими разраьотчиками
- Быстрее спросить, чем потом ждать раскатку фикса

Подглядывание

- Из-за множественной проверки гипотез увеличивается вероятность увидеть изменение, когда его нет

Нельзя:

- Принимать решение о раскатке эксперимента, как только ключевая метрика первый раз «позеленела»
- Стопать эксп сразу, как только он покраснел. Сначала нужно оценить эффект

Подглядывание

Можно:

- Подглядывать, но принимать решение только через фиксированный заранее определенный срок
- Выключить эксперимент, если метрики сильно упали (после получения аппрува)
- Использовать последовательный анализ
- Смотреть изменение p-value в динамике

Множественная проверка гипотез

- Раскатывать эксп по результатам каждого день (подглядывание)

«прокрасилась ли метрика» -> «прокрасилась ли метрика хотя бы раз» (нельзя)

- Смотреть на несколько метрик в АВ-тесте

«прокрасилась ли метрика» -> «прокрасилась ли хотя бы одна метрика» (осторожно)

Несколько метрик в AB-тесте

Вероятность того, что случайно прокрасится хотя бы одна из k метрик:

$$1 - (1 - 0.05)^k$$

k = 1 => 5%

k = 2 => 10%

k = 3 => 14%

k = 4 => 19%

k = 5 => 23%

…

k = 10 => 40%

Несколько метрик в AB-тесте

Вероятность того, что случайно прокрасится хотя бы одна из k метрик:

$$1 - (1 - 0.05)^k$$

Решение:

- Поправки для уровня значимости
- Четко сформулированная гипотеза

Что может пойти не так?

ВОПРОСЫ?

Как устроен процесс проведения AB-тестов в hh

1. Дискавери – брейнштормы, качественные и количественные исследования итд Принимают участие **все** члены команды
2. Сгенерированные гипотезы обсуждаются на уровне архитерктуры, времени разработки и дизайна
3. Одобренные гипотезы отправляются на дизайн [тех налог пропускает данный шаг]
4. После утвреждение дизайна составляется дизайн эксперимента и начинается разработка, при необходимости добавляются новые события на фронте и беке
5. Фича тестируется и отправляется на прод. Запускается AB-тест
6. Мониторинг здоровья AB-теста и тех. Параметров
7. Подвение итогов теста. Принимается решение о раскатке. На встрече обсуждения итогов также присутсвует вся команда

Выводы

- **Гипотеза и метрика**: формулируем гипотезу как одно ключевое изменение → одна целевая метрика, конкретная аудитория/место воздействия и ожидаемый эффект (например, “+x%”).
- **Случайное разбиение**: A/B работает, потому что группы в среднем оказываются в одинаковых условиях — это “сглаживает” влияние фона (трафик, другие изменения).
- **Детерминированное назначение по hash(user_id + salt)** : хэш даёт стабильное попадание в группу, а **соль** нужна, чтобы не копить эффекты прошлых экспериментов и уметь запускать/разделять эксперименты корректно.
- **Единица анализа = пользователь (независимость)**: тестам нужна независимость наблюдений, поэтому обычно считают одно значение на пользователя, иначе растёт шанс ложных выводов.
- **Статвывод формируется по p-value и α** статистический тест считает тестовую статистику и p-value; правило $p < \alpha \rightarrow$ отвергаем H_0;.
- **Что “ломает” A/B и даёт ложные прокрасы**: перекос групп, подглядывание/мультипроверки (много метрик или сегменты), сетевые эффекты (взаимовлияние пользователей) и ошибки в событиях/логировании

Примеры экспериментов

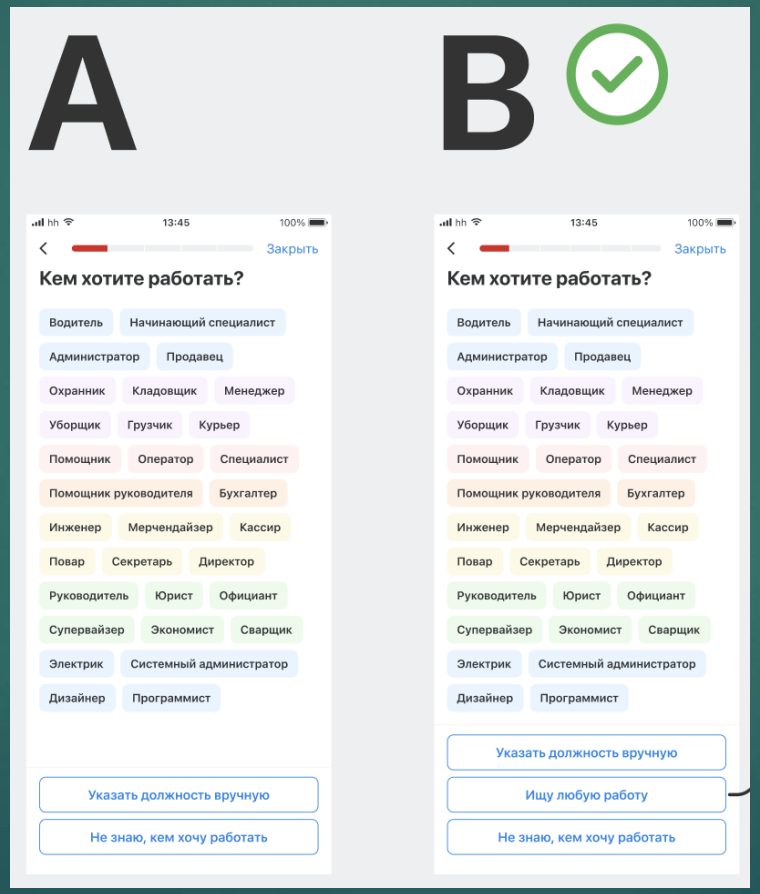

Примеры экспериментов

A

B

Примеры экспериментов

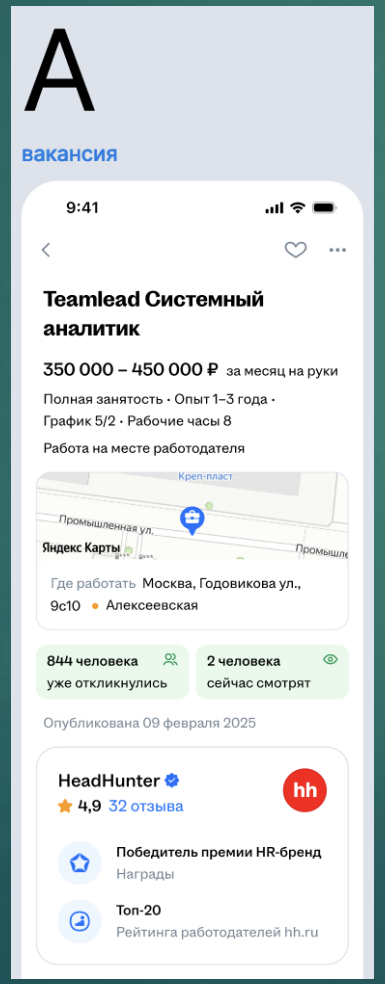

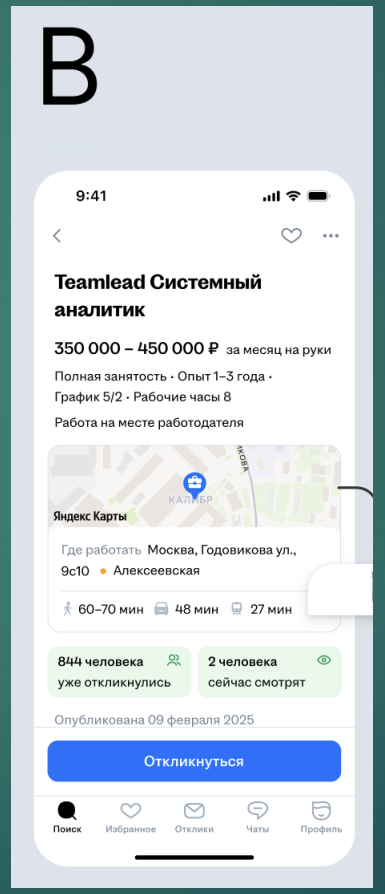

AB-тесты для разработчиков

ВОПРОСЫ?